

Miniprojet de Datavisualisation

RDSM - ROAD

Matthieu SALLE

Gayathiri RAVENDIRANE

```
data_raw <- read_excel("atmo_polluants_Périgueux.xlsx", sheet = 2) # Importation de jeu de données
```

Introduction

Description des données

```
nLigne <- nrow(data_raw)
print(nLigne)
```

```
## [1] 8696
```

```
pColonne <- ncol(data_raw)
print(pColonne)
```

```
## [1] 27
```

Le jeu de données contient 8 696 lignes (~362 jours * 24 heures) et 27 colonnes. Chaque ligne représente une heure de mesure pour une station de mesure. Chaque colonne représente une variable mesurée ou une information sur la mesure (date, pression, polluant, etc.).

La date est une unité statistique, les variables statistiques sont les autres colonnes.

```
cat("Date début\n")
```

```
## Date début
```

```
cat(format(data_raw$date_debut[1], "%Y-%m-%d %H:%M:%S"), "\n")
```

```
## 2023-11-08 00:00:00
```

```
cat("Date fin\n")
```

```
## Date fin
```

```
cat(format(data_raw$date_debut[nLigne], "%Y-%m-%d %H:%M:%S"), "\n")
```

```
## 2024-11-07 00:00:00
```

La période de mesure s'étend du 08/11/2023 de 00:00h au 07/11/2024 jusqu'à 00:00h.

```
# str(data_raw)
```

Le jeu de données contient des variables de différents types : numériques (double), catégorielles (chr) et des dates (date).

Cleaning des données

On regarde d'abord si il y a des valeurs manquantes dans le jeu de données.

```
# data_raw$PM2.5 == NA # que des `NA` partout
```

On voit que la colonne 'PM2.5' contient que de valeurs manquantes (NA). Nous allons donc pas l'inclure dans notre analyse.

```
data_raw <- data_raw %>% select(-PM2.5)
```

```
pColonne <- ncol(data_raw) # mettons à jour le pColonne
```

Objectif de l'analyse et Choix des variables

L'objectif de cette analyse est d'étudier la relation entre la concentration d'ozone (O_3) et les conditions météorologiques à Périgueux sur une période d'un an. Nous nous interrogerons sur les facteurs susceptibles d'influencer la formation et le niveau d' O_3 , une molécule constituée de trois atomes d'oxygène, produite à la suite de réactions chimiques complexes impliquant différents paramètres atmosphériques. Plus précisément, nous chercherons à déterminer quelles conditions météorologiques (température, humidité, pression, variation de pression à 3 heures et point de rosée) ont le plus d'impact sur la concentration d'ozone. Dans cette approche, O_3 sera la variable à expliquer, tandis que les variables explicatives représenteront les caractéristiques physiques de l'atmosphère au cours de la période étudiée.

```
data <- data_raw |>
  select(
    date_debut, jour, heure, O3, temperature, pression, pression_variation_3h, humidite, point_de_rosee)
```

On ajoute une colonne "saison" pour pouvoir faire des analyses saisonnières par la suite.

```
data <- data %>%
  mutate(date_time = as.POSIXct(date_debut, format = "%Y-%m-%d %H:%M:%S")) %>%
  mutate(month = month(date_time)) %>%
  mutate(
    season = case_when(
      month %in% c(12, 1, 2) ~ "Hiver",      # Décembre, Janvier, Février
      month %in% c(3, 4, 5) ~ "Printemps",  # Mars, Avril, Mai
      month %in% c(6, 7, 8) ~ "Été",        # Juin, Juillet, Août
```

```

    month %in% c(9, 10, 11) ~ "Automne" # Septembre, Octobre, Novembre
  )
) %>%
select(-date_time, -month)

```

Univariée

Dans un premier temps, étudions les mesures statistiques et la distribution de chaque variable de notre jeu de données afin d'avoir une idée sur la façon dont chaque valeurs sont réparties.

```

fill_color <- c("steelblue", "#7a937c", "#2e4045", "#a76168", "violet", "pink")
plot_x <- c("O$_3$", "Température (°C)", "Pression (hPa)", "Pression (hPa/3h)", "Humidité (g/m³)", "Point de rosée")
plot_y_count <- "Count"
plot_y_density <- "Density"

```

Boite à moustaches (Boxplots)

```

# 1. O3
boxplot_o3 <- ggplot(data, aes(x = O3) ) +
  geom_boxplot(fill = fill_color[1]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())

# 2. Température
boxplot_temp <- ggplot(data, aes(x = temperature) ) +
  geom_boxplot(fill = fill_color[2]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())

# 3. Pression
boxplot_press <- ggplot(data, aes(x = pression) ) +
  geom_boxplot(fill = fill_color[3]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())

# 4. Pression variation de 3h
boxplot_pressVar3h <- ggplot(data, aes(x = pression_variation_3h) ) +
  geom_boxplot(fill = fill_color[4]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())


# 5. Humidité
boxplot_humidity <- ggplot(data, aes(x = humidite) ) +
  geom_boxplot(fill = fill_color[5]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())

# 6. Point de rosée
boxplot_pointRosee <- ggplot(data, aes(x = point_de_rosee) ) +
  geom_boxplot(fill = fill_color[6]) +
  theme(axis.title.y = element_blank(), axis.text.y = element_blank(), axis.ticks.y = element_blank())

grid.arrange(boxplot_o3,
              boxplot_temp,

```

```
boxplot_press,
boxplot_pressVar3h,
boxplot_humidity,
boxplot_pointRosee,
nrow=3, ncol=2)
```



Interprétation des boxplots

- (1) Le boxplot de l'ozone (O_3) montre une médiane autour de 55 $\mu\text{g}/\text{m}^3$, centrée dans la boîte, ce qui traduit une distribution équilibrée et homogène. L'absence de valeurs aberrantes indique peu de fluctuations extrêmes, la majorité des concentrations étant comprises entre 30 et 70 $\mu\text{g}/\text{m}^3$.
- (2) Concernant la température, la médiane proche du centre suggère également une répartition symétrique des valeurs. Toutefois, plusieurs outliers, selon la règle des 1.5 fois l'écart interquartile, apparaissent aux deux extrémités : températures très élevées (épisodes de canicule) et basses (vagues de froid). La moitié des observations se situe entre 9°C et 17°C, avec une médiane proche de 13°C. Ces épisodes extrêmes pourraient influencer la formation d'ozone, favorisée par les fortes chaleurs.
- (3) Le boxplot de la pression atmosphérique révèle une boîte resserrée autour de 1018 hPa, donc peu de variabilité. Quelques outliers sont présents entre 980 et 1040 hPa, reflétant des épisodes inhabituels possiblement liés à des systèmes météorologiques extrêmes (anticyclones ou dépressions). Il serait intéressant d'examiner si ces fluctuations de pression influencent les niveaux d'ozone.
- (4) La variation de pression sur 3 heures présente une médiane à 0, signe d'une stabilité générale à court terme. Néanmoins, la présence d'outliers dans les deux directions indique des variations ponctuellement marquées. La question du lien entre variation de pression et la O_3 se pose de façon similaire à celle de la pression atmosphérique.

- (5) Le boxplot de l'humidité relative montre des valeurs globalement élevées, centrées autour de 87%, entre 75% et 95%. Quelques outliers sous 45% témoignent d'épisodes d'air très sec, rares mais notables.
- (6) Enfin, pour le point de rosée, la distribution est symétrique autour d'une médiane proche de 10°C. Les valeurs principales se situent entre 6°C et 14°C, avec des outliers extrêmes (vers 0°C et au-delà de 20°C). Ces épisodes d'air particulièrement sec ou humide pourraient également influencer les concentrations d'ozone.

Histogram Plots

```
bins <- 30

# 1. O3 - Histogramme simple
histPlot_o3 <- ggplot(data, aes(x = O3) ) +
  geom_histogram(bins = bins, fill = fill_color[1]) +
  labs(x = plot_x[1], y = plot_y_count) +
  theme_minimal()

# 1. O3 - Histogramme avec densité
histPlot_o3_density <- ggplot(data, aes(x = O3)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[1]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[1]) +
  labs(x = plot_x[1], y = plot_y_density) +
  theme_minimal()

# 2. Temperature - Histogramme simple
histPlot_temp <- ggplot(data, aes(x = temperature) ) +
  geom_histogram(bins = bins, fill = fill_color[2]) +
  labs(x = plot_x[2], y = plot_y_count) +
  theme_minimal()

# 2. Temperature - Histogramme avec densité
histPlot_temp_density <- ggplot(data, aes(x = temperature)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[2]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[2]) +
  labs(x = plot_x[2], y = plot_y_density) +
  theme_minimal()

# 3. Pression - Histogramme simple
histPlot_press <- ggplot(data, aes(x = pression) ) +
  geom_histogram(bins = bins, fill = fill_color[3]) +
  labs(x = plot_x[3], y = plot_y_count) +
  theme_minimal()

# 3. Pression - Histogramme avec densité
histPlot_press_density <- ggplot(data, aes(x = pression)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[3]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[3]) +
  labs(x = plot_x[3], y = plot_y_density) +
  theme_minimal()

# 4. Pression variation de 3h - Histogramme simple
```

```

histPlot_pressVar3h <- ggplot(data, aes(x = pression_variation_3h) ) +
  geom_histogram(bins = bins, fill = fill_color[4]) +
  labs(x = plot_x[4], y = plot_y_count) +
  theme_minimal()

# 4. Pression variation de 3h - Histogramme avec densité
histPlot_pressVar3h_density <- ggplot(data, aes(x = pression_variation_3h)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[4]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[4]) +
  labs(x = plot_x[4], y = plot_y_density) +
  theme_minimal()

# 5. Humidité - Histogramme simple
histPlot_humidity <- ggplot(data, aes(x = humidite) ) +
  geom_histogram(bins = bins, fill = fill_color[5]) +
  labs(x = plot_x[5], y = plot_y_count) +
  theme_minimal()







# 5. Humidité - Histogramme avec densité
histPlot_humidity_density <- ggplot(data, aes(x = humidite)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[5]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[5]) +
  labs(x = plot_x[5], y = plot_y_density) +
  theme_minimal()

# 6. Point de rosée - Histogramme simple
histPlot_pointRosee <- ggplot(data, aes(x = point_de_rosee) ) +
  geom_histogram(bins = bins, fill = fill_color[6]) +
  labs(x = plot_x[6], y = plot_y_count) +
  theme_minimal()


# 6. Point de rosée - Histogramme avec densité
histPlot_pointRosee_density <- ggplot(data, aes(x = point_de_rosee)) +
  geom_histogram(aes(y = after_stat(density)), bins = bins, fill = fill_color[6]) +
  geom_density(aes(y = after_stat(density)), alpha = 0.2, fill = fill_color[6]) +
  labs(x = plot_x[6], y = plot_y_density) +
  theme_minimal()

grid.arrange(histPlot_o3, histPlot_o3_density,
              histPlot_temp, histPlot_temp_density,
              histPlot_press, histPlot_press_density,
              nrow=3, ncol=2)

```



```
grid.arrange(histPlot_pressVar3h, histPlot_pressVar3h_density,
             histPlot_humidity, histPlot_humidity_density,
             histPlot_pointRosee, histPlot_pointRosee_density,
             nrow=3, ncol=2)
```



Interprétation des histogrammes

- (1) Dans l'histogramme de la concentration d' O_3 on observe que les valeurs de O_3 sont assez étalées : la plupart sont comprises entre 0 et environ 100, avec une majorité située autour de 55 à 70. La présence d'une petite pic, autour de 10 et 30, (près de 410 occurrences) à gauche et beaucoup de valeur sur la partie gauche de du pic centrale (près de 600 occurrences) indique que la distribution est légèrement asymétrique (légèrement étalée vers les fortes concentrations). On voit qu'il existe plusieurs valeurs faibles (près de zéro), mais aussi un nombre non négligeable de valeurs élevées (jusqu'à 120). La courbe noire lissée permet de mieux saisir la forme globale de la distribution : il n'y a pas un pic unique, mais une zone centrale où la concentration d' O_3 est la plus fréquente ; de plus, les fréquences diminuent progressivement vers les extrêmes. **On peut donc conclure que la majorité des niveaux d'ozone restent dans une plage intermédiaire, mais des épisodes de faible ou de forte pollution existent.**
- (2) L'histogramme simple de température (premier graphique) montre que la majorité des températures sont regroupées entre 7°C et 20°C, avec un pic autour de 11°C. La distribution présente un seul pic principal et il y a une légère asymétrie vers les hautes valeurs, avec une traîne qui s'étend progressivement jusqu'à environ 40°C. Le second graphique, combinant histogramme et courbe de densité, met en évidence cette observation : la densité maximale est autour de 11°C, la distribution reste centrée mais s'étale davantage pour les valeurs élevées, traduisant des épisodes de chaleur moins fréquents mais bien présents. **Cette distribution suggère que les températures dans les données sont majoritairement modérées, mais des épisodes de températures élevées existent.**
- (3) L'histogramme simple de pression (premier graphique) met en avant que la majorité des valeurs de pression sont regroupées entre 1000 et 1025 hPa, avec un pic de fréquence autour de 1015 hPa. La distribution présente un unique sommet central et une symétrie globale, mais une traîne qui s'étend lentement vers les valeurs extrêmes, aussi bien pour les pressions basses que hautes. Le second graphique,

combinant histogramme et courbe de densité, confirme cette impression : la densité maximale coïncide avec le pic de l'histogramme, et la courbe suit une forme quasi-gaussienne centrée autour de 1015 hPa, mais avec une légère dispersion aux deux extrémités. **Cette distribution suggère que les pressions atmosphériques dans les données sont essentiellement standards, bien que l'on observe parfois des épisodes de pressions basses ou hautes.**

- (4) L'histogramme simple de la variation de pression sur 3 heures (premier graphique) montre que la majorité des variations sont très faibles, centrées autour de 0 hPa/3h, avec un pic de fréquence très marqué à cette valeur. La distribution présente une forte concentration des valeurs proches de zéro, indiquant que la pression reste généralement stable sur de courtes périodes. Cependant, on observe aussi une traîne qui s'étend vers les variations plus importantes, tant positives que négatives, bien que ces occurrences soient nettement moins fréquentes. Le second graphique, combinant histogramme et courbe de densité, confirme cette impression : la densité maximale est très proche à zéro, et la courbe descend rapidement pour les variations plus extrêmes. **Cette distribution suggère que les variations de pression sont généralement minimales, mais des épisodes de changements brusques existent.**
- (5) L'histogramme simple de l'humidité (premier graphique) révèle que la majorité des valeurs d'humidité sont élevées, principalement entre 80% et 100%, avec un pic marqué autour de 95%. La distribution est asymétrique, avec une concentration nette vers les hautes valeurs et une traîne qui s'étend vers les valeurs plus basses. Le second graphique, combinant histogramme et courbe de densité, confirme cette observation : la densité maximale coïncide avec le pic de l'histogramme, et la courbe montre une forte inclinaison vers les hautes humidités. **Cette distribution suggère que l'air dans les données est majoritairement humide, bien que des épisodes d'air sec soient également présents.**
- (6) L'histogramme simple du point de rosée (premier graphique) indique que la majorité des valeurs se situent entre 5°C et 20°C, avec un pic autour de 10°C. La distribution est relativement symétrique autour de ce pic, mais on observe une légère traîne vers les valeurs plus élevées ou faible, inférieures à 0°C ou supérieures à 20°C. Sur le second graph, la densité maximale correspond au pic de l'histogramme, et la courbe suit une forme quasi-gaussienne centrée autour de 10°C. **Cette distribution suggère que le point de rosée dans les données est généralement modéré, bien que quelques épisodes d'air très humide ou très sec.**

Bivariée

on va d'abord chercher la corrélation entre les variables explicatives et notre variable à expliquer, O_3 ; puis il s'agira de modéliser cette dépendance à l'aide de la régression linéaire. Si plusieurs variables influencent le niveau d' O_3 , alors on fera une régression multiple avant de voir grâce à l'ACP, quelles variables permettent d'expliquer tant de pourcents du niveau de l' O_3 .


la comparaison des moyennes peut tout à fait relever de la statistique bivariée, à condition qu'elle implique deux variables : une variable explicative (généralement qualitative) et une variable à expliquer (quantitative).

Corrélation entre O_3 et les variables explicatives

```
vars <- c("temperature", "pression", "humidite", "point_de_rose")

correlations <- sapply(data[vars], function(x) cor(x, data$O3, use = "complete.obs"))
barplot(sort(abs(correlations), decreasing = TRUE), las = 2, col = "steelblue", main = "Corrélation abs
```

Corrélation absolue avec O3



Interpretation

on remarque 2 categories :

- 1) humidité/ température
- 2) pression/point_de_rosee

on fera attention ici, on est en corrélation absolue, autrement dit on ne prends pas en compte le signe; ça peut être une corrélation positive ou négative; on remarque néanmoins que les variables humidité et température sont les variables les plus corrélées à O₃ (c'est à dire que O₃ évolue de la manière la plus régulière avec la variable humidité), et pression/ point de rose le sont moins.

Il s'agira ensuite de voir quelles sont les variables les plus corrélées positivement avec O₃ grâce à la régression linéaire, et voir la force de l'effet unitaire de chacune de leur pentes.

Régression linéaire simple, avec un filtre à la p-value de <0.05

```
vars_significatives <- c()
for (v in vars) {
  model <- lm(O3 ~ data[[v]], data = data)
  p_value <- summary(model)$coefficients[2, 4]
  r_squared <- summary(model)$r.squared
  coef <- summary(model)$coefficients[2, 1]

  if (!is.na(p_value) && p_value < 0.05) {
    vars_significatives <- c(vars_significatives, v)
    cat("\n", v,
        "\n - p-value :", round(p_value, 4),
        "\n - pente :", round(coef, 4),
        "\n - R² :", round(r_squared, 4), "\n")
  }
}
```

```
##
## temperature
## - p-value : 0
## - pente : 1.8704
## - R2 : 0.2232
##
## pression
## - p-value : 0
## - pente : -0.8944
## - R2 : 0.0848
##
## humidite
## - p-value : 0
## - pente : -1.1214
## - R2 : 0.3834
##
## point_de_rose
## - p-value : 0
## - pente : 1.0798
## - R2 : 0.0448
```

Interpretation

Tout d'abord, on remarque que toutes les variables sont significatives car elles ont toutes une p-value inférieure à 0.05. On remarque ensuite que 2 variables sont positivement corrélées à O₃ (température (et point de rose) et deux autres sont négativement corrélées à O₃ (humidité et pression).

Plus le niveau de la température et du point de rose augmente, plus celui d'O₃ augmente (resp de 1.8 et 1.0). Plus l'humidité et la pression augmentent, plus le niveau d'O₃ diminue (resp de 1.1 et 0.8); on fait ce constat en regardant la valeur de la pente des variables.

Pour autant, la variable qui explique le plus la variabilité de O₃ est l'humidité car son R² est le plus élevé des variables avec une valeur de 0.38, suivi de la température avec une valeur de 0.22, c'est à dire que ces variables expliquent respectivement 38% et 22% de l'évolution des niveaux de O₃.

Ainsi, le point de rosée est une variable secondaire, la pression a un effet modéré, la température est pertinente et explicative, et l'humidité est la variable la plus explicative ;

L'humidité est donc le meilleur prédicteur

La régression multiple va permettre de voir comment évolue o3 en modifiant une variable mais en gardant les autres constantes.

Régression Multiple: Modéliser O₃ avec toutes les variables significatives en même temps

```
model_multi <- lm(O3 ~ temperature + pression + humidite + point_de_rose, data )
summary(model_multi)
```

```
##
## Call:
## lm(formula = O3 ~ temperature + pression + humidite + point_de_rose,
##     data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
```

```
## -68.969 -14.291 0.478 14.797 61.689
##
## Coefficients:
##           Estimate Std. Error t value      Pr(>|t|)
## (Intercept)  960.48311    25.69524   37.380 < 0.0000000000000002 ***
## temperature   -0.51635     0.16167   -3.194    0.00141 **
## pression      -0.80037     0.02485  -32.202 < 0.0000000000000002 ***
## humidite      -1.21132     0.04070  -29.761 < 0.0000000000000002 ***
## point_de_rose  0.72345     0.16092    4.496    0.00000702 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 20.14 on 8691 degrees of freedom
## Multiple R-squared:  0.4584, Adjusted R-squared:  0.4582
## F-statistic: 1839 on 4 and 8691 DF, p-value: < 0.00000000000000022
```

Tout d'abord, on constate qu'avec seulement ces quatre variables, on peut expliquer 45.8% de la variabilité de O_3 en regardant le R^2 , ce qui montre que ce modèle est relativement solide.

On observe que, lorsque chaque variable — température, pression ou humidité — augmente individuellement, tout en maintenant les autres constantes, le niveau d'ozone diminue. Seul le point de rosée présente un effet inverse : à variables constantes, son augmentation entraîne une hausse du niveau d'ozone.

On remarque une différence par exemple entre la régression multiple et la régression simple de la variable température; ici elle a une pente négative car cette pente est calculée en gardant les autres variables comme étant des constantes, alors que dans la régression simple, le niveau de pente est décrit individuellement, prenant en compte qu'une variable et l'ozone.


(A MODIFIER PEUT ETRE, vu que régression simple et multiple donnent les mêmes résultats, un séparément, l'autre ttes ensembles ou pas? à revoir)

ACP (réduire la dimension et identifier les variables les plus explicatives)

```
acp <- prcomp(data[vars], scale. = TRUE) # ACP sur les variables explicatives
summary(acp) # Résumé des composantes
```

```
## Importance of components:
##           PC1      PC2      PC3      PC4
## Standard deviation  1.4884 1.0036 0.8701 0.14267
## Proportion of Variance 0.5538 0.2518 0.1893 0.00509
## Cumulative Proportion 0.5538 0.8056 0.9949 1.00000
```


```
plot(acp, type = "l", main = "Variance expliquée par les composantes principales") # Graphique de la va
```



Heatmap des corrélations

```
numerical_vars <- names(data)[sapply(data, is.numeric)]
numerical_data_raw <- data[sapply(data, is.numeric)] # Identifie les variables numeriques

correlation_matrix <- cor(numerical_data_raw)
corrplot(correlation_matrix, method = "color", type = "upper", addCoef.col = "black", tl.col = "black",
```



Le heatmap révèle les relations entre couples de variables. Par exemple, une forte corrélation positive entre la température et le point de rosée indique que ces deux paramètres évoluent ensemble. Inversement, la corrélation négative entre O3 et humidité suggère que l'ozone tend à diminuer lorsque l'humidité augmente.

Conclusion